Hệ thống cảnh báo bất thường giá và lượng

Chuẩn bị dữ liệu, thiết kế feature và lựa chọn mô hình

Phạm vi: repo Price-and-Quantity-Anomaly-Detection-Company (chuỗi xuất nhập khẩu hàng tháng, 2009-01 đến 2026-08). Mục tiêu cuối cùng là xây dựng hệ thống cảnh báo; làm trước với các chuỗi có dữ liệu đầy đủ nhất, bắt đầu từ gạo xuất khẩu.

Kết luận ngắn: dữ liệu gốc không cần thêm hay bớt dòng nào, nhưng cần chuẩn hoá vài thứ và nên bổ sung một số biến bên ngoài. Về mô hình, không có mô hình "tốt nhất" duy nhất: benchmark hiện nay cho thấy phương pháp thống kê đơn giản vẫn rất cạnh tranh, còn foundation model cho chuỗi thời gian là lựa chọn đáng thử thêm.

1. Dataset có cần chỉnh không

Nên làm (không thêm dữ liệu mới)

- Đặt lịch tháng liên tục cho mọi chuỗi và giữ nguyên NaN, không nội suy.
- Tạo đơn giá = tri_gia / so_luong và lấy log cho cả ba chỉ tiêu (lượng, trị giá, đơn giá).
- Xác nhận đơn vị và loại số liệu (số từng tháng hay số lũy kế).
- Lưu thêm phiên bản dữ liệu (vintage) nếu nguồn có điều chỉnh số liệu sau khi công bố.

Nên bổ sung biến bên ngoài (exogenous)

Nhiều "bất thường" thật ra chỉ là biến động vĩ mô, nên các biến sau giúp giảm cảnh báo giả:

- Giá dầu Brent (giải thích biến động giá xăng dầu và dầu thô).
- Tỷ giá USD/VND.
- Giá gạo quốc tế, giá thép (HRC hoặc phôi).
- Lịch: tháng, số ngày làm việc, cờ Tết. Tết âm lịch rơi vào tháng 1 hoặc tháng 2 tuỳ năm, dễ gây cảnh báo giả nếu chỉ dùng "tháng" làm mùa vụ.

Chronos-2 hỗ trợ dự báo zero-shot đa biến với biến đồng hành (covariates) bên ngoài, nên có thể tận dụng các biến này. Giai đoạn 1 chưa cần biến ngoài; có thể thêm sau khi baseline chạy ổn.

2. Feature: phụ thuộc vào loại mô hình

- **Mô hình dựa trên sai số dự báo** (như prototype ETS): gần như không cần feature thêm, vì sai số chuẩn hoá chính là điểm bất thường.
- **Mô hình dựa trên vector đặc trưng** (Isolation Forest, ECOD, LOF, Mahalanobis): cần feature. Với 212 điểm mỗi chuỗi, giữ khoảng 8–12 feature, không nhiều hơn.

Nhóm	Feature gợi ý
Thay đổi	log-MoM, log-YoY (y_t − y_{t−12})
So với quá khứ	z-score và percentile trong 12/24 tháng trước, dạng robust (median/MAD)
Dồn nhiều tháng	tổng 3 tháng so với cùng kỳ năm trước; lũy kế từ đầu năm so với năm trước
Giá và lượng	z(giá) − z(lượng); đơn giá lệch so với median trượt

Nhóm	Feature gợi ý
Từ mô hình khác	sai số chuẩn hoá của ETS hoặc SARIMA dùng như một feature
Lịch	sin/cos theo tháng, cờ Tết, số ngày làm việc

Lưu ý quan trọng cho hệ thống cảnh báo: mọi thống kê trượt chỉ được dùng dữ liệu đến tháng t−1 (dùng shift(1)), không dùng cửa sổ căn giữa (center=True) hay STL hai chiều. Khung code mẫu ở lượt tư vấn đầu dùng cửa sổ căn giữa, phù hợp để khám phá dữ liệu nhưng không dùng được cho cảnh báo thật vì sẽ nhìn thấy tương lai. Script alert_prototype.py đã xử lý đúng điểm này.

3. Mô hình và thuật toán

Nhóm	Thuật toán	Vai trò
A. Baseline	Seasonal-naive, robust z trên phần dư, ETS / SARIMA / Theta	Bắt buộc có; dễ giải thích. Prototype hiện đã có ETS.
B. ML không giám sát	Isolation Forest, ECOD/COPOD (PyOD), LOF, robust Mahalanobis	Trên vector feature; bắt bất thường kết hợp giữa giá và lượng.
C. Foundation model	Chronos-2, TimesFM-2.5, TiRex, Moirai 2.0	Dự báo phân vị; cảnh báo khi giá trị thực nằm ngoài khoảng (ví dụ ngoài 1%–99%).
D. Deep learning chuyên anomaly	LSTM-AE, Anomaly Transformer, TimesNet	Không khuyến nghị cho chuỗi 212 điểm.

Nhóm C: foundation model (mới nhất)

- Trên benchmark GIFT-Eval, Chronos-2 vượt TiRex và TimesFM-2.5, hai mô hình dẫn đầu trước đó. Trên một benchmark khác gồm chủ yếu chuỗi ngắn (dưới 300 bước), Chronos-2 cũng đứng đầu, phù hợp với chuỗi 212 tháng.
- Dữ liệu tần suất thấp có lợi: khi tần suất giảm, foundation model càng cạnh tranh.
- Không nên tin thứ hạng quá tuyệt đối. Bảng của Reverso cho thấy các mô hình đầu bảng chênh nhau rất ít (MASE khoảng 0.70–0.72), và Chronos-2 đạt 0.698 khi có rò rỉ dữ liệu so với 0.720 khi không. Bài Chronos-2 cũng thừa nhận kho dữ liệu huấn luyện có chồng lấn một phần với phần train của một số dataset trong GIFT-Eval.

Nhóm D: deep learning

Benchmark TSB-AD cho thấy kiến trúc đơn giản và phương pháp thống kê thường cho kết quả tốt hơn mạng nơ-ron phức tạp; mạng nơ-ron hứa hẹn hơn ở bài toán đa biến, còn foundation model hứa hẹn ở bất thường điểm. Bất thường của dữ liệu này chủ yếu là bất thường điểm hàng tháng, nên kết luận khá phù hợp.

Biến dự báo thành cảnh báo đáng tin: conformal calibration

Một công trình năm 2026 xây khoảng tin cậy conformal thích ứng từ dự báo của foundation model, cho điểm bất thường diễn giải trực tiếp thành tỷ lệ cảnh báo giả hoặc p-value. Đây đúng là thứ hệ thống cảnh báo cần: chọn trước mức chấp nhận (ví dụ khoảng 1 cảnh báo giả mỗi chuỗi mỗi năm)

rồi hiệu chỉnh ngưỡng theo đó. Thách thức chính vẫn là phân biệt bất thường thật với thay đổi phân phối, mô hình sai cấu trúc và biến động vô hại, càng cho thấy vì sao cần biến ngoài như giá dầu và tỷ giá.

4. Cấu hình đề xuất cho hệ thống

1. **Tầng 1:** ETS/SARIMA + robust z (đã có, dễ giải thích).
2. **Tầng 2:** Chronos-2 zero-shot với dự báo phân vị, thêm Brent và tỷ giá khi cần.
3. **Tầng 3:** Isolation Forest hoặc ECOD trên vector feature nhỏ để bắt bất thường kết hợp.
4. **Kết hợp:** chuẩn hoá về rank/percentile, gộp điểm, rồi hiệu chỉnh ngưỡng bằng conformal.

Chỉ giữ tầng nào thắng baseline trong backtest của chính dự án. Không nên tin vào chọn mô hình tự động: nghiên cứu TSB-AutoAD phát hiện hơn một nửa các biến thể tự động hoá không hơn chọn ngẫu nhiên và 75% kém hơn chiến lược chọn mô hình tốt nhất toàn cục đơn giản.

Đánh giá cần hai lớp (dự báo tốt chưa chắc phát hiện tốt)

- **Chất lượng dự báo:** MASE, độ phủ khoảng tin cậy (khoảng 90% phải phủ khoảng 90% số tháng thực tế), pinball loss.
- **Chất lượng phát hiện:** PR-AUC, precision@k, recall trên bất thường giả lập, số cảnh báo mỗi năm. Nếu sau này có nhãn thật, thước đo TSB-AD dùng là VUS-PR, được nhóm tác giả xác định là thước đo đáng tin nhất.

5. Chuỗi ưu tiên và kết quả prototype

Mức	Chuỗi	Ghi chú
Đủ 212/212 tháng	Xuất khẩu: gạo, sắt thép các loại, xăng dầu các loại, dầu thô	Làm trước. Gạo đầu tiên: mùa vụ rõ nhất, đơn giá ổn định.
Gần đủ (200 tháng)	Nhập khẩu: xăng dầu, khí đốt hóa lỏng, phân bón, phế liệu sắt thép, sắt thép các loại	Làm sau nhóm đầu.
Ngắn hơn	Xuất khẩu phân bón (188), clanhke và xi măng (164)	Làm sau.
Để sau	Nhập khẩu dầu thô, than đá, ure	Thiếu nhiều hoặc đứt đoạn; chạy riêng đoạn liên tục.
Không dùng được	Sản phẩm từ sắt thép (nhập và xuất)	Cả hai cột đều không có dữ liệu hợp lệ.

Thứ tự đề xuất: gạo → sắt thép xuất khẩu → xăng dầu xuất khẩu → dầu thô xuất khẩu → 5 chuỗi nhập khẩu 200 tháng.

Kết quả backtest gạo xuất khẩu (ETS một chiều, 2014–2026): rất ít cảnh báo (1 CRITICAL vào 2025-10, 1 WARN năm 2026). Độ nhạy khác nhau nhiều giữa các chỉ tiêu: lượng nhiễu khoảng 25% mỗi tháng nên tháng bị nhân đôi chỉ bị bắt khoảng 43%; đơn giá có sai số khoảng 4% nên là tín hiệu sắc nhất. Đây là kết quả từ một chuỗi và bất thường giả lập, chỉ nên coi là mức tham khảo; chưa xác minh 2025-10 có phải sự kiện thật.

Đơn giá cho thấy đơn vị có vẻ là tấn và USD, nhưng đây là suy luận cần xác nhận lại với nguồn dữ liệu.

6. Việc tiếp theo

1. So sánh trực tiếp ETS (đã có) với Chronos-2 trên gạo xuất khẩu, dùng cùng cách backtest và cùng bộ bất thường giả lập, để xem foundation model có thắng đáng kể không (cần chạy trên máy có truy cập Hugging Face).
2. Chạy alert_prototype.py trên sắt thép, xăng dầu, dầu thô xuất khẩu và so sánh độ nhạy giữa các chuỗi.
3. Thêm cảnh báo tổng 3 tháng cho lượng và đo lại bằng bất thường giả lập.
4. Tự lập danh sách vài sự kiện thật của gạo để kiểm tra mô hình có bắt được không.
5. Chốt kênh nhận cảnh báo (email, Slack, dashboard hoặc báo cáo HTML) để thiết kế đầu ra.

Nguồn tham khảo

- Liu & Paparrizos (2024), The Elephant in the Room: Towards A Reliable Time-Series Anomaly Detection Benchmark (TSB-AD), NeurIPS 2024. openreview.net/forum?id=R6kJtWsTGy
- Liu, Lee & Paparrizos, TSB-AutoAD: Towards Automated Solutions for Time-Series Anomaly Detection. vldb.org/pvldb/vol18/p4364-liu.pdf
- Ansari et al., Chronos-2: From Univariate to Universal Forecasting. arxiv.org/pdf/2510.15821
- Reverso: Efficient Time Series Foundation Models for Zero-shot Forecasting. arxiv.org/pdf/2602.17634
- Post-Training in Time Series Foundation Models: A Unifying Framework (mục 7.4, Anomaly Detection). arxiv.org/pdf/2607.20002